

東 北 大 學

硕士学位论文开题报告及论文工作计划书

学 号： 2272122

姓 名： 李强

导 师： 冯朝路

学科类别： ☐ 工学 ☒ 全日制专业学位

学科/工程领域： 人工智能

所属学院： 计算机科学与工程学院

研究方向： 计算机视觉

拟选题目： 基于深度学习的点云配准方法

研究与应用

选题时间： 2023 年 8 月 1 日

东北大学研究生院

2023 年 11 月 26 日

填表说明

- 1、本表应在导师指导下如实填写。
- 2、学生在开题答辩前一周，将该材料交到所在学院、研究所。
- 3、按有关规定，没有完成开题报告的学生不能申请论文答辩。
- 4、全文正文均用小四号宋体，单倍行距，段前段后间距为 0，如果页数不够，可以整页扩页，其他格式要求参见《东北大学硕、博士学位论文格式》。

一、前期工作基础（本节可以整页扩页）

课程学习及选题开题阶段，在导师指导下从事研究工作总结（不少于 2000 字）

点云是由在三维空间中分布的大量点组成的数据集合，每个点通常包含其在空间中的位置信息（X, Y, Z 坐标），有时还可能包含颜色、强度和其他属性信息。这种数据结构在计算机视觉、三维建模、地理信息系统（GIS）和各种工程应用中非常重要，能够精确地表现出物体或场景的外形和空间结构，是数字化实体世界的一种有效手段。点云数据通常通过各种类型的扫描设备获取，例如激光扫描仪（在测量工程和地形测绘中使用）、立体视觉相机（在计算机视觉中使用）和光学扫描仪（在工业检测和文化遗产记录中使用）。这些设备能够从不同的视角捕捉物体或场景的三维信息，生成大量的点来代表被扫描对象的表面。

点云配准是一种在三维空间中对齐两个或多个点云数据集的过程，它在计算机视觉、机器人技术、医学成像等多个领域中扮演着关键角色。点云配准的核心目标是确定一种变换，使得两个或多个点云可以在统一的坐标系统中准确对齐。配准过程通常开始于预处理步骤，包括滤波去噪、降采样以及特征提取。这些步骤旨在改善数据质量，提取有用信息，从而简化后续的配准工作。

点云配准的一个主要挑战是如何处理大规模数据和确保高精度。随着深度学习等先进技术的引入，点云配准方法正在变得更加精确和高效。这些技术可以更好地处理复杂场景和特征稀疏的点云，提高配准的准确性和鲁棒性。

点云配准的应用非常广泛，从工业机器人的精准定位、自动驾驶车辆的环境理解，到历史遗迹的三维重建和医学影像的融合，都离不开精确的点云配准技术。随着技术的进步，点云配准在未来可能会支持更复杂的应用，如增强现实（AR）和虚拟现实（VR）中的实时三维重建等。点云配准作为三维空间数据处理的一个关键环节，其在许多高科技领域中都发挥着不可或缺的作用，也就有着巨大的研究意义。

基于此知识背景，本人决定从最新的点云配准技术入手，针对其不足，拟采用基于深度学习的点云配准研究与应用作为课题，来弥补前人方法的不足，并在性能准确率上取得先进的效果。另外，还对于点云配准的相关知识进行学习和分析，并系统性总结了点云处理领域常用的数据集及点云配准领域常用的评价指标。

1. 数据集总结

在点云领域，这些数据集通常被用于测试和比较不同算法的性能，如点云配准、分类、分割等。以下是一些常用的点云数据集：

1) ModelNet

ModelNet 是一个大型的 3D 模型数据集，主要用于三维物体识别和分类。它包含多种类别的三维模型，可以转换为点云形式进行使用。

应用：三维对象识别、分类。

2) ShapeNet

ShapeNet 是一个丰富的三维形状数据集，包含多个类别的三维物体模型。这些模型可以用于点云生成、分析和处理的研究。

应用：三维形状分析、语义分割、对象识别。

3) Stanford 3D Scanning Repository

这个数据集由斯坦福大学提供，包含多个精心扫描的三维对象和场景。这些高质量的数据集对于测试三维重建和点云配准算法非常有用。

应用：三维重建、点云配准。

4) KITTI Vision Benchmark Suite

主要用于移动机器人和自动驾驶领域的研究，KITTI 数据集包括用于环境感知的多种传感器数据，如激光雷达（LiDAR）点云和相机图像。

应用：自动驾驶、环境感知、点云与图像融合。

5) Semantic3D

专注于大规模城市和农村环境，Semantic3D 是大规模室外场景的语义标注点云数据集。

应用：语义分割、大规模点云处理。

6) Paris-Lille-3D

包含大量的城市街道场景点云，由移动激光扫描系统采集，适用于测试点云分割和分类方法。

应用：点云分割、分类。

7) Auckland's Tamaki Campus

由奥克兰大学提供，包含用车载激光雷达扫描的大型室外环境点云数据。

应用：点云配准、环境建模。

这些数据集提供了多样化的三维点云数据，覆盖了从小型对象到复杂城市环境的各种场景。它们是研究和开发点云处理算法不可或缺的资源，同时也推动了该领域的技术进步和创新，而对于本课题的点云配准来说，ModelNet、KITTI Vision Benchmark Suite、ShapeNet 等都是可以进行支撑实验的，在前人的研究中大多都采用了 ModelNet 或者 ShapeNet 进行实

验，本课题也将重点从这两个数据集入手，必要时构建适用于本课题的专属数据集。

2. 常用评价指标

1) Chamfer Distance (CD)

Chamfer Distance 的计算方法较为简单，它是两个点云之间的最小距离的平均值，用于衡量两个点云之间的相似度。

$$CD(S_1, S_2) = \frac{1}{|S_1|} \sum_{x \in S_1} \min_{y \in S_2} \|x - y\|_2 + \frac{1}{|S_2|} \sum_{y \in S_2} \min_{x \in S_1} \|y - x\|_2$$

Chamfer Distance 计算简单，速度快，所以在点云配准领域常有一席之地，但它也有一些缺点，例如对于点云中的噪声和离群点比较敏感，同时也不能很好地区分点云中不同的部分。因此，在实际应用中，需要根据具体情况选择合适的距离度量方法。

2) 点云重叠率 (Overlap Ratio)

它是两个点云之间的重叠部分占总点数的比例，公式计算也较简单易懂。

$$OverlapRatio = \frac{overlapNUM}{totalNUM}$$

点云重叠率越高，说明两个点云之间的重叠部分越多，也就意味着它们之间的匹配程度越高，在点云配准中，点云重叠率可以作为一种粗略的评价指标，用于快速筛选出匹配程度较高的点云对，从而缩小搜索空间，提高配准效率。

3) 对称平均距离 (Symmetric Mean Distance, SMD)

它是两个点云之间的平均距离，即每个点到对应点的距离的平均值。

$$SMD(P, Q) = \frac{1}{2N} \sum_{i=1}^N (\|p_i - q_i\| + \|q_i - p_i\|)$$

对称平均距离的优点是能够很好地区分点云中不同的部分，同时也比较鲁棒，对于点云中的噪声和离群点也比较稳健。但它也有一些缺点，例如计算复杂度较高，同时也不能很好地反映点云之间的全局相似度。

除了以上这些之外，在点云配准领域的评价指标还有很多，例如均方根误差 (RMSE)、最大误差 (Max Error)、RRE 和 RTE 等等均可以从不同的角度来度量点云配准效果的好坏。

3. 前期实验准备

1) 传统方法实验

在前期准备工作中，进行了传统方法 ICP 算法，及其衍生算法 Go-ICP 的实验，数据采用经典的斯坦福兔子点云模型进行实验。结果分别如图 1、图 2 所示

图左侧分别为计算出的变换矩阵和配准准确度量值，在右图中，红色兔子为原始数据源点云，绿色兔子为进行刚体变换后目标点云，蓝色兔子为将绿色兔子做向红色兔子变换后的配准结果。



图 1 ICP 算法测试

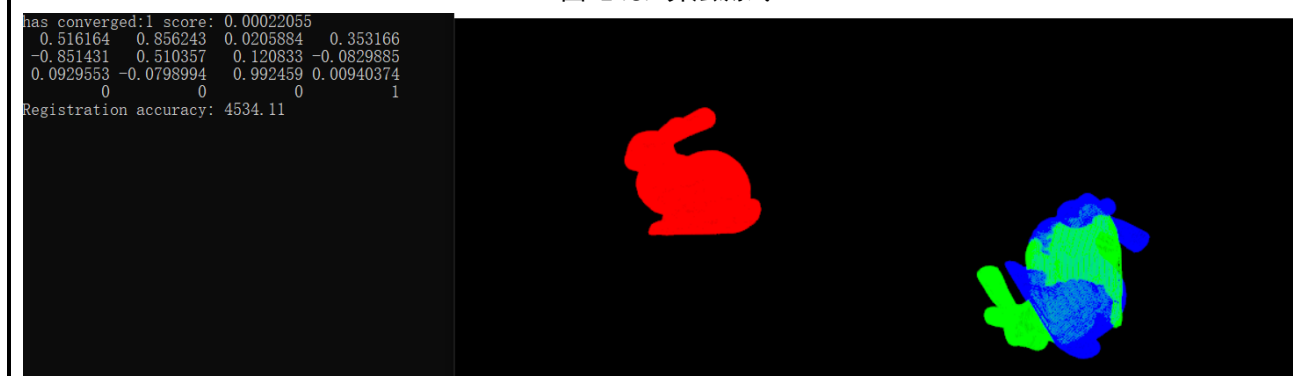


图 2 Go-ICP 算法测试

可见，两种方法均陷入局部最优解，在参考其他算法得知传统方法大多适用于精匹配，而如需达到较好的效果，需要粗配准的辅助进行，因此开展下一步结合粗配准进行实验。（这里的粗配准是根据生成绿色兔子的变换矩阵给了一个初始的变换矩阵）结果如图 3 所示。




图 3 粗配准与精配准相结合实验

这里的黄色兔子是不采用粗配准给出的变换矩阵，直接使用 ICP 算法得出的变换矩阵所配准的效果，可见蓝色兔子和红色兔子已经重合在一起，所以在传统方法中，一个初值的好坏可以影响精配准的效果。

2) 基于学习类方法的测试

接下来测试基于学习类的配准实验，这里使用近期开源的 GeoTransformer 模型进行的实验，由于训练次数有限，得到的效果并未达到预期，但是已经可以说明该方法的可行性。测试结果如图 4 所示。

```
has converged:1 score: 0.126891
1 0.000464177 8.48822e-05 0.00819746
-0.0004641 0.999999 -0.000909135 -0.00208284
-8.53042e-05 0.000909095 1 -0.000315214
0 0 0 1
Registration accuracy: 7.88076
```




图 4 GeoTransformer 模型测试

可见，蓝色兔子的姿态与红色兔子姿态基本上是一样的，也就表面，GeoTransformer 对于几何特征提取具有先进性，但是整体上并未重合，所以可能在离群点处理，全局特征的融合上存在一定不足。

4. 总结

经过这些的前期准备工作，本人已经对该研究方向所需要做的工作有了大致清晰的理解，有了进行本课题研究的大致思路，基本梳理出入手点和创新点，也有了数据集和评价指标的选择问题，为本课题的顺利开展进行奠定了一定基础。

二、选题依据（本节可以整页扩页）

课题背景、选题依据、课题研究目的、理论意义和应用价值（工学硕士）/工程背景和实用价值（专业学位硕士）（不少于 1000 字）

1. 选题背景

近些年来，信息技术飞速发展，自动驾驶、三维打印、机器视觉等技术逐渐走入人们的生活当中，而三维重建技术在此之中起到了关键作用，该技术通过扫描获取目标场景的表面点云并加以处理，最终建立该场景的三维数字模型。要实现高精度的三维重建，则需要高精度的点云配准技术来支撑，它是三维计算机视觉中的一个重要研究课题，不仅仅在三维重建中，在地图构建（Simultaneous Localization and Mapping, SLAM）、数据融合、增强现实等领域都有着重要的应用与价值。

目前，越来越多的学者加入深度学习的研究行列，也就产生了越来越多的基于深度学习的方法，这些方法基本都有效解决了问题，甚至在效果上比传统算法还要好，三维视觉领域也不例外，越来越多的学者尝试在点云处理方向应用深度学习，来完成例如点云分割，点云识别，点云补全，点云配准等任务，一部分已经取得了很好的效果，但是由于算力的限制，点云数据的特点等等因素，在此方向的研究并未达到真正的预期效果。

2. 选题依据

点云是 3D 数据的一种表达形式，它保留了几何物体的空间信息，存储形式简单，易于理解，因此成为许多三维计算机视觉应用的首选表示方式。然而，由于视角以及设备的限制，不可能单次扫描中获取该场景的所有表面点云，受环境遮挡，物体本身的姿态以及设备参数等影响，采集到的三维点云数据往往只是物体表面的一部分，为了重建获得物体整体的表面点云数据，需要将不同视角下得到的具有重叠部分的局部点云进行配准处理，即通过平移旋转操作将不同视角的点云对齐在同一坐标系下。如何从重叠区域找到用于配准的“匹配点对”是匹配算法的关键所在，传统方法中，查找匹配点对时会计算几何特征的相似性，但是对点云的初始位置要求较为严格，需要在空间上有一定的重叠部分才能获得较好的配准效果。为了使配准自动化，经过许多学者的研究，大量的点云自动配准算法被提出，使得点云配准无需人工参与，应用最为广泛的是迭代最近点（Iterative Closest Point, ICP）算法及其改进方法，该类方法往往依赖于良好的点云初始位置，也就是要在使用前对点云进行粗匹配，且容易陷入局部最优解。此外，该类方法不能很好应对带有噪声、结构缺失以及只具有少部分重合的点云数据。

3. 课程研究目的

基于深度学习的点云配准技术在理论上 also 具有重要的意义。它为深度学习模型在三维数

据处理中的应用提供了新的思路和方法，同时提高了点云配准的效率和准确性，为点云数据处理的进一步发展提供了新的思路和方法。该技术可以通过自动学习点云之间的相似性和差异性，实现自适应匹配和鲁棒性强的点云配准。这种方法可以避免传统点云配准方法中需要手动选择匹配点的问题，提高了点云配准的效率和准确性。同时，基于深度学习的点云配准技术能够处理点云之间的噪声、缺失和变形等问题，具有较强的鲁棒性。

4. 工程背景和实用价值

随着机械化制造和数字化制造的发展，机器人已由点对点应用发展至离线编程轨迹应用。针对各工作场景，对机器人进行离线编程轨迹是如今各大主流机器人厂商的优势区域。此类编程方式在针对刚性对象的加工中完成度较好。但对压铸件、橡胶件、超大型工件等变形量无法有效控制的加工对象进行加工时，离线编程轨迹的方法将不再适用。针对此类痛点，使用 3D 视觉传感器进行实物 3D 建模，完成机器人在线轨迹生成是重要的解决办法，然而此类技术在当前各大机器人厂商与集成商中尚未得到充分的研究。其主要原因基于 3D 视觉的机器人在线轨迹生成方法存在多学科交叉，需突破多个关键技术，如针对复杂干扰情况的有效成像技术、高精度的成像系统标定、高精度的点云拼接配准、高精度的点云补全、高精度手眼标定等，需要掌握机器视觉、机器人控制等多个学科的专业知识。因此，当前基于 3D 机器视觉的机器人工艺轨迹在线生成技术研究尚未完善且该技术存在大量蓝海场景，具有较高的研究价值。

由于待测的工件样式多变，具有不同的形状、材质、颜色和反射性质等，如何合理的进行视觉传感器选型与设计是首先需要解决的问题，此外由于单位置的视觉传感器视场有限，为获得工件的完整数字模型，通常需要在多个位置采集工件的点云子块再进行拼接。但是获取到的单工具不同视角下的点云不完全相同，需要配准技术进行处理才能得到一个完整的点云数据，如何根据当前已有点云自适应的完成点云配准同样需要进行研究，点云配准结果的好坏也会影响着工艺的精确度和效率。

同样的，在三维建模中，点云配准技术可以帮助将多个点云数据集中的点云进行对齐，以实现更加准确的三维建模。在机器人导航中，点云配准技术可以帮助机器人识别环境中的障碍物和目标物体，从而实现更加精确的导航。在地质勘探中，点云配准技术可以帮助地质工程师更好地理解地质结构和地貌特征，从而实现更加准确的勘探。在医学图像处理中，点云配准技术可以帮助医生更加准确地进行病灶定位和手术规划。具有较高的工程应用价值，

而如今，基于深度学习方法与优化方法的组合进一步提高了点云配准的性能，属于当前点云配准领域研究的热点问题。但是该技术现阶段发展仍有着多方面的困难，例如在硬件方

面的算力支持，3D 点云的相关处理通常有较大的数据量和较大的计算量，如果没有足够的硬件条件，该方面的实验将难以进行。而点云由于其无序性，导致其几何特征很难得到，但是将重点关注于局部的几何特征时，往往又忽略了全局的特征，导致网络总是对特征的提取不够完全。深度学习在于点云上的应用探索才仅仅 6 年左右，并没有像图像方面的模型技术那样多样化成熟化，更需要学者进行进一步的研究。本文旨在研究一种基于深度学习的高精度的点云配准方法，在提高性能的基础上，结合注意力机制最大限度的减少陷入局部最优解的可能。

三、文献综述（本节可以整页扩页）

国内外研究现状、发展动态描述（不少于 1000 字）；所阅文献的查阅范围及手段，附参考文献（不少于 10 篇，其中近 3 年文献不少于 5 篇，英文文献不少于 3 篇，全部按照标准格式列出，并在文中顺序标注）

1 介绍

点云配准作为点云处理中的一大关键技术，在西方国家已经有 30 余年的研究历史，国内外学者从理论研究的角度，对点云配准的实现方法有较为深入的研究。目前国内也已经开展了很多对于配准方法的研究。国内外相关研究证实将深度学习网络用于点云配准任务是具有可行性和较高应用价值的，但是对于基于 Transformer 相关模型部分的分析不多，仍有较大可发掘的空间。基于此，本文将针对基于深度的点云配准进行实证研究，此研究是在国内外学者对点云配准网络的广泛研究基础之上进行的，借鉴了他们的一些研究结论与研究方法，为本文开阔思路。

2 国内外研究现状

在检索一些国内外文献后，本文发现根据实现方法，点云配准可以大致分为两类，分别是基于传统方法的点云配准和基于深度学习的点云配准。

2.1 关于传统方法的点云配准的定义

基于传统方法的点云配准的过程通常可以分为粗配准和精配准两个阶段，粗配准的目的是将两个点云的大致位置和方向对齐，使得后续的精细对齐更容易。粗配准通常是通过计算点云之间的全局特征，如点云的质心、法向量、表面曲率等，来确定两个点云之间的初始变换矩阵。精配准的目的则是在粗配准的基础上，最小化两个点云集合之间的刚性变换误差。

2.1.1 关于 ICP 算法及其衍生算法的研究

在传统方法中，由 Besl 和 McKey[1] 在 1992 年提出的迭代最近点算法 (Iterative Closest Point, ICP) 是一种最经典的点云配准算法，具体而言该方式是一种基于最小二乘法的点云配准方法，先计算两个点云之间的最近点对来初始化变换矩阵，然后通过迭代的方式将一个点云变换到与另一个点云相似的位置和方向。在每一次迭代中，都会计算两个点云之间的最近点对，进而来计算变换矩阵。这个过程会一直重复，直到两个点云之间的距离达到一个预设的阈值或达到最大迭代次数为止。ICP 算法原理简单易懂，易于实现，但是非常容易陷入局部最优解，也很依赖初始值，因此诸多学者在 ICP 算法的基础上做了改进，衍生出各种 ICP

算法的变种算法。

例如 Andrew[2]所提出的 LM-ICP 算法就是 ICP 算法的一种变种，它主要是针对 ICP 算法的收敛性和计算效率问题进行改进。LM-ICP 算法在每次迭代时，先计算 ICP 算法的迭代步长，然后根据 Levenberg-Marquardt 算法的思想，将步长乘以一个系数，从而得到新的迭代步长。这个系数是一个动态调整的参数，可以根据当前的迭代情况来自适应地调整。并且利用 DT (Distance-Transform) 算法代替 KD-tree 算法来搜索最临近点，可以减小初始位置对配准过程的影响，并且通过这种方式，LM-ICP 算法也可以避免 ICP 算法的收敛性问题，并且在计算效率上也有所提高。

Jacopo Serafin 等人[3]在 ICP 算法的基础上，结合一种稠密法向量的计算方法，提出了 NICP (Normal based Iterative Closest Point) 算法。该算法首先计算点云的法向量，然后将法向量作为点云的一个属性，与点的坐标一起进行配准。在迭代过程中，算法通过最小化点云之间的距离来不断优化变换矩阵，直到收敛为止。通过利用点云的法向量信息进行约束，可以更好地处理点云的非刚性变形和局部噪声等问题，从而提高点云配准的精度和鲁棒性。此外，算法还采用基于 KD-tree 的快速搜索方法，可以加速算法的收敛速度，从而适用于大规模点云配准问题。

J. Yang 等人[4]则是利用分支定界算法设计了一种全局最优的迭代式最近点算法 (Globally Optimal Iterative Closest Point, Go-ICP)。首先分支定界搜索通过对初始解空间进行划分，降低搜索空间，提高搜索效率。在每次迭代时，该算法将点云划分为多个子空间，并对每个子空间进行配准，得到多个候选解，然后选择最有可能得到全局最优解的子空间进行下一轮迭代，逐步缩小搜索空间，最终得到全局最优解。该算法还使用了一种新颖的权重策略，通过对点云中的点进行加权，使得算法更加鲁棒，能够应对不同的噪声和干扰。Q. Zhou 等人[5]提出了快速全局配准算法 (Fast Global Registration, FGR)，该算法首先将点云划分为多个层次，每个层次包含不同的点云密度，然后通过逐层配准的方式，将点云从低密度到高密度进行配准，从而实现全局点云配准。FGR 算法还使用了一种新颖的全局优化方法，称为 ICP-UM (Iterative Closest Point with Uncertainty Modeling)。该方法可以在点云配准过程中考虑点云之间的不确定性，从而提高配准的精度和鲁棒性。

2.1.2 关于基于特征的配准方法的研究

然而上述方法仍无法有效解决陷入局部最优解的问题，所以在应用中通常用于精配准过程，需要粗配准算法的辅助进行。进而有一些学者做了其他方面的尝试，例如基于手动设计的特征获得匹配关系。如美国加州大学洛杉矶分校 (UCLA) 的 Rusu 等人[6]在 2009 年提出的

快速点特征直方图 (Fast Point Feature Histogram, FPFH)、以及南京大学的 Shen[7]等人提出的方向直方图 (Signature of Histograms of Orientations, SHOT) 等已经取得了显著的效果, 这类方法通常首先从输入的原始点云中提取关键点和特征描述符。其次利用异常值剔除法和最近邻算法选择内部关键点, 获得更准确的关键点对应关系。最后估计从源点云到目标点云的转换, 尝试来避免陷入局部最优解的问题。然而, 这类方法对异常值和重复几何结构很敏感, 缺乏点云的语义信息, 因此精度和鲁棒性均不理想。

2.2 关于基于深度学习的配准方法的定义

深度学习在如今已经取得了很多进展, 越来越多的算法都通过深度学习进一步提高了性能, 因此有诸多学者尝试将深度学习应用于点云数据, 以实现点云配准任务的高质量完成。

2.2.1 关于基于 PointNet 及 PointNet++的配准方法的研究

在 2017 年, Charles 等人[8]提出了首个可以直接处理点云数据的深度学习模型 PointNet, 该网络主要分为两个部分: 特征提取网络和分类网络。特征提取网络用于提取点云的局部特征并融合为全局特征, 分类网络中有多个全连接层和激活函数, 用于将全局特征映射于分类标签上。但是该网络对局部特征信息并不敏感, 针对此问题, Charles 等人[9]结合最远点采样算法 (Farthest Point Sampling, FPS) 又提出了 PointNet++网络, 在一定程度上弥补了 PointNet 对局部特征不敏感的缺陷, 进一步提高了点云分类, 分割等任务的准确率。随后更多学者将深度学习应用于点云配准上, 诸多点云配准网络模型也随之提出。

2019 年, 斯坦福大学的 Aoki 等[10]学者提出了 PointNetLK 网络模型, 将点云配准问题转化为一个回归问题, 也就是 PointNetLK 将点云的初始变换矩阵参数作为输入, 利用 PointNet 分别提取两片输入点云的全局特征, 然后通过估计变换矩阵, 最小化两个特征之间的特征差异, 预测出点云的最终变换矩阵参数, 从而完成点云配准工作。

另外, Sarode V. 等人[11]提出的 PCNet, 同样使用 PointNet 作为骨架来计算每个输入点云的特征向量, 然后使用最大池化的方式得到全局特征向量, 不同的是, PCNet 最后使用一系列全连接层回归配准参数, 最终经过广泛的实验发现该方法, 在几个基准数据集上都表现出了优秀的性能和效率。

2.2.2 关于尝试 Transformer 注意力机制与点云配准结合的研究

在 Transformer 于机器翻译, 文本信息处理等领域展现出强大地位后, 诸多学者尝试将该模型与点云数据的处理网络相结合, 对点云配准技术的发展起到了积极作用。

Y. Wang 等人[12]基于动态图卷积神经网络 (Dynamic Graph Convolutional Neural Network, DGCNN) 结合 ICP 算法的流程设计出了深度最近邻点算法 (Deep Closest Point, DCP)。该算法首先用动态图卷积神经网络提取点的特征, 之后结合 Transformer 注意力机制将点云间的信息融合, 计算出局部特征区域的匹配点, 之后利用奇异值分解 (Singular Value Decomposition, SVD) 线性求解得到变换矩阵。之后 Y. Wang 等人[13]进一步研究了针对非完全重叠点云的配准问题, 提出了可迭代式点云配准算法 (Parametric Reshaping Network, PRNet), 通过设置迭代次数和增加约束条件滤除了部分不存在匹配点的外点的干扰, 实现可以在不同角度和光照条件下对点云进行配准, 提高了点云配准的准确性和鲁棒性。

Fu 等人[14]结合了 Transformer 结构提出了一种基于深度图匹配的点云配准网络, Transforemer 结构作为该网络的边生成器, 可以充分考虑到每个点的局部边结构特征, 以及将特征提取范围扩大到更大的拓扑结构范围, 从而找到每个点之间的对应关系, 在求解变换矩阵时也是用到了奇异值分解的方法, 但是该方法由于 Transformer 进行上下文信息编码时会忽略几何特征, 会导致网络学习到的特征不具有较高的几何特性, 从而产生异常。

为了使 Transformer 结构能学习到几何特征, Qin 等人[15]提出了 GeoTransformer 方法, 该方法通过对超点对之间的距离信息和角度信息进行编码并嵌入到 transformer 中, 实现了有效的全局结构信息学习, 也正因如此, GeoTransformer 对于低重叠的点云之间的配准效果同样很好, 在配准 Recall 上, REGTR 和 GeoTransformer 在 3DMatch 数据集上都达到了 92.0%, 足够证明该方法的有效性和处理部分场景时的先进性。

同样还有其他学者尝试了将注意力机制应用于点云配准算法, 例如 Yew 等人[16]提出了 REGTR 网络框架, 使用注意力机制来取代特征匹配和 RANSAC, 搭建出一个端到端的框架来直接预测最终的对应点集, 之后使用预测出的对应点集合直接计算变换矩阵做刚性变换, 而无需进一步处理。该方法在 3DMatch 数据集的表现, 无论从处理速度还是准确率都达到了很高的水平, 其处理速度超过了此前的所有方法, 并且 REGTR 在高分辨率的数据上可以达到更好的效果。

在处理具有重叠部分的点云匹配网络算法的设计上, Xu 等人[17]-[18]设计出了基于重叠区域掩模预测的部分重叠点云配准算法与一种基于双分支特征交互的部分重叠点云配准算法, 前者学习重叠区域掩模来屏蔽非重叠点, 也就是显式地预测输入点云的重叠区域掩模, 再利用该掩膜来对非重叠区域进行屏蔽, 避免在对应点的匹配过程中产生影响。后者的算法设计核心是在特征提取模块中加入了点云数据间的多级特征交互, 使得输入点云间的特征信息在处理早期即可进行交换, 而无需使用注意力机制来赋予特征提取器对于自身全局信息与

其他点云信息的感知能力，相比之下减小了内存消耗与计算量。而在精度上后者也较前者有了一定提升。

2.2.3 关于其他基于学习的配准方法的探索研究

由 Lu 等人[19]提出的一种名为 DeepVCP 的点云配准方法。它是一种基于端到端学习的 3D 点云配准框架，与上述方法不同的是，DeepVCP 使用了一种称为 Variational Continual Point Cloud (VCP) 的方法来表示点云数据，并使用了一种新的损失函数来优化点云配准。VCP 是一种基于变分自编码器的点云表示方法，能够将点云数据压缩到一个低维空间中，并在此空间中进行配准，也就是说 DeepVCP 不是在现有点云中搜索对应匹配点，而是先学习基于候选点之间匹配概率之后重新生成虚拟对应点。DeepVCP 还使用了一种新的损失函数来优化点云配准。该损失函数基于点云之间的距离，并结合 soft-argmin[20]技术来计算点云之间的最小距离，实现保持点云的局部结构不变的同时，优化点云之间的全局对齐。

Z. J. Yew 等人[21]提出了基于传统算法 RPM 的深度学习方法 RPMNet，使用一个神经网络来预测最佳的退火参数，提高了算法灵活性。再用学习到的融合特征更新网络的收敛方式，使得 RPMNet 可以实现迭代执行并收敛，提高了特征匹配的精确度。

Huang 等人[22]提出了一种快速半监督的无对应点云配准方法，该方法使用半监督学习框架来学习配准函数，即使用少量的标注数据来训练学习过程，并利用无标注数据来提高配准的鲁棒性和泛化能力。该方法还使用了一种快速的特征采样和匹配策略，特征差异越小，说明点云配准的效果越好。

W. Yuan 等人[23]提出了基于深度学习配准方法 DeepGMR，结合潜在高斯混合模型 (Gaussian Mixure Model, GMM) 与深度卷积神经网络学习图像之间的相似性，使得每个点都对应着一个特征，并且相似的图像会被映射到相近的位置。所以在配准时，DeepGMR 可以通过计算待配准图像的位置和其他图像的位置之间的距离来实现配准。相似的，Ao 等人[24]为了让网络学习到更多局部特征，提出了 SpinNet。SpinNet 的核心思想就是将点云划分为若干个区域，并对每个区域结合旋转不变性进行卷积操作来学习具有高通用性和鲁棒性的点云局部特征。

对于非刚性配准中异常值剔除问题，Qin 等人[25]提出基于图的空间一致性网络 (Graph-based Spatial Consistency Network, GraphSCNet) 来过滤非刚性配准的离群点，该方法是围绕非刚性变形的局部刚性设计的，即非刚性变形是局部等距的，以此来保持点云的局部形状，此外，作者设计并结合了一种基于注意力机制的图对应嵌入模块来提取空间对应关系，

此模块在进一步的操作中也用于分离内点与异常点，该方法在 4DMatch 基准的高重叠和低重叠场景中的测试表现均处于最先进的队列。

3 总结

综上所述，本文认为前人对点云配准研究与认识较为深入。本文借鉴这些方法，进一步对该领域进行研究。

近期，关于提高点云配准网络的性能和轻量化的研究比较重视，但是对点云配准网络对离群点和噪声过度敏感的分析较少，这就限制了研究思路的拓展。对于离群点和噪声对模型的影响，各学者的研究结论也有所出入，部分学者发现离群点剔除模块可有效提高配准效果，而部分学者认为应从特征学习和匹配角度来避免离群点的产生，而文献中专门研究两者相结合的较少。

本文以基于 GeoTransformer 点云配准网络为研究对象，拟在多尺度特征提取和离群点剔除方法的理论基础上，采用多尺度特征提取模块的方法对 GeoTransformer 进行改进，提高其对特征的学习能力，提高模型的鲁棒性，并且在此模型的基础上进行实证研究，并建立增强网络模型，进一步对网络的鲁棒性和性能进行提高。本文的研究也将用于企业项目的研究进程上，为获取高精度的点云模型提供基础和技术，有利于工艺水平的提高。

由此可见，基于传统的点云配准方法与基于深度学习的点云配准方法，无论在实现方法还是在应用上都有着较大差异，但是对于基于深度学习的点云配准方法依然有着可探索提升空间，有着较高的应用价值，有待国内外学者进行进一步的研究。

所查阅文献的范围及手段：

通过企业及企业实验室的局域网，以及通过校外 VPN 服务，访问如 CVPR、ICCV、IROS、ICRA 等高质量期刊会议官网；通过百度学术查找本领域的高被引论文；登陆校内图书馆网站，下载国内外大量的电子版文献进行集中阅读。

在查阅论文时使用的具体办法是，先确定好研究方向的领域，在该领域找出具有代表性的综述类文章，然后确定具体的研究方向或者技术，在网络上查找相关总结以及查阅近期的优秀综述，在对该领域有一定了解后，根据自己感兴趣的几个关键技术点（关键词）搜索相关领域论文，然后在知网、百度学术以及顶会期刊上找到优质文章，同时也包括近些年的优秀的硕博论文，能为论文行文结构与表述组织提供参考。接着根据不同的细分方向和研究难点，选出代表性论文进行阅读，再针对其中遇到的特别的算法和技术问题，细化关键词进行

进一步查阅。所查阅文献的范围如下表所示：

数据库名称	时间跨度
中国学术期刊全文数据库	2017-2023
中国优秀博硕士学位论文数据库	2017-2023
中国学术会议论文数据库	2017-2023
中国学位论文数据库	2017-2023
外文检索数据库	1992-2023
SCI（科学引文索引）	1992-2023
Ei Village（工程索引网络版）	1992-2023
Google 学术	2017-2023
百度学术	2017-2023

表 1 查阅文献所属数据库及范围

参考文献：

- [1] Makay B P. A Method for Registration of 3D Shape[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1992, 14: 239-256.
- [2] Fitzgibbon A. W. Robust registration of 2D and 3D point sets[J]. Image and vision computing, 2003, 21(13-14): 1145-1153.
- [3] J. Serafin and G. Grisetti, "NICP: Dense normal based point cloud registration," 2015 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), Hamburg, Germany, 2015, pp. 742-749, doi: 10.1109/IROS.2015.7353455.
- [4] Yang Jiaolong, Li Hongdong, Campbell D., et al. Go-ICP: A globally optimal solution to 3D ICP point-set registration[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 38(11): 2241-2254.
- [5] Q.Zhou,J.Park,V.Koltun. Fast global registration[C].Proc.ECCV,2016,766-782
- [6] R. B. Rusu, N. Blodow and M. Beetz, "Fast Point Feature Histograms (FPFH) for 3D registration," 2009 IEEE International Conference on Robotics and Automation, Kobe, Japan, 2009, pp. 3212-3217, doi: 10.1109/ROBOT.2009.5152473.
- [7] Shen Z, Ma X, Li Y. A Hybrid 3D Descriptor with Global Structural Frames and Local Signatures of Histograms[J]. IEEE Access, 2018, 6: 39261-39272.
- [8] Charles R. Q., Su Hao, Mo Kaichun, et al. PointNet: Deep learning on point sets for 3d classification and segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Honolulu: IEEE Press, 2017: 652-660.
- [9] Charles R. Q., Yi Li, Su Hao, et al. PointNet++: deep hierarchical feature learning on point sets in a metric space[C]//Advances in neural information processing systems. Long Beach: NIPS Press, 2017: 5099-5108.
- [10] Aoki Y, Goforth H, Srivatsan R A, et al. Pointnetlk: Robust & Efficient Point Cloud Registration Using

- Pointnet[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019: 7163-7172.
- [11] Sarode V., Li Xueqian, Goforth H., et al. PCRNet: Point Cloud Registration Network using PointNet Encoding[DB/OL]. arXiv, 2019-11-3[2022-3-15], <https://arxiv.org/abs/1908.07906>.
- [12] Y.Wang,J.M.Solomon.Deep closest point:Learning representations for point cloud registration[C].Proc.ICCV,2019,3523-3532
- [13] Y.Wang,J.M.Solomon.Prnet:Self-supervised learning for partial-to-partial registration[C]. Proc.NeurIPS,2019,8814-8826
- [14] K. Fu, S. Liu, X. Luo and M. Wang, "Robust Point Cloud Registration Framework Based on Deep Graph Matching," 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Nashville, TN, USA, 2021, pp. 8889-8898, doi: 10.1109/CVPR46437.2021.00878.
- [15] Z. Qin et al., "GeoTransformer: Fast and Robust Point Cloud Registration With Geometric Transformer," in IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 45, no. 8, pp. 9806-9821, Aug. 2023, doi: 10.1109/TPAMI.2023.3259038.
- [16] Z. J. Yew and G. H. Lee, "REGTR: End-to-end Point Cloud Correspondences with Transformers," 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), New Orleans, LA, USA, 2022, pp. 6667-6676, doi: 10.1109/CVPR52688.2022.00656.
- [17] Hao Xu,Shuaicheng Liu,Guangfu Wang,Guanghui Liu,Bing Zeng.OMNet:Learning Over- lapping Mask for Partial-to-Partial Point Cloud Registration[C].Proc.ICCV,Montreal,Canada, 2021,3132-3141.
- [18] Hao Xu,Nianjin Ye,Guanghui Liu,Bing Zeng,Shuaicheng Liu.FINet:Dual Branches Fea- ture Interaction for Partial-to-Partial Point Cloud Registration[C].Proc.AAAI,Online,2021.
- [19] Lu Weixin, Wan Guowei, Zhou Yao, et al. DeepVCP: An end-to-end deep neural network for point cloud registration[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Seoul: IEEE Press, 2019: 12-21.
- [20] Benjamin Coors, Alexandru Paul Condurache, and Andreas Geiger. 2018. SphereNet: Learning Spherical Representations for Detection and Classification in Omnidirectional Images. In Computer Vision – ECCV 2018: 15th European Conference, Munich, Germany, September 8–14, 2018, Proceedings, Part IX. Springer-Verlag, Berlin, Heidelberg, 525–541.
- [21] Yew Z. J., Lee G. H. RPM-Net: Robust point matching using learned features[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. Virtual: IEEE Press, 2020: 11824-11833.
- [22] X. Huang, G. Mei and J. Zhang, "Feature-Metric Registration: A Fast Semi-Supervised Approach for Robust Point Cloud Registration Without Correspondences," 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Seattle, WA, USA, 2020, pp. 11363-11371, doi: 10.1109/CVPR42600.2020.01138.
- [23] W.Yuan,B.Eckart,K.Kim,et al.Deepgmr:Learning latent gaussian mixture models for registration[C].Proc.ECCV,2020,733-750

- [24] S. Ao, Q. Hu, B. Yang, A. Markham and Y. Guo, "SpinNet: Learning a General Surface Descriptor for 3D Point Cloud Registration," 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Nashville, TN, USA, 2021, pp. 11748-11757, doi: 10.1109/CVPR46437.2021.01158.
- [25] Z. Qin, H. Yu, C. Wang, Y. Peng and K. Xu, "Deep Graph-based Spatial Consistency for Robust Non-rigid Point Cloud Registration," 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, BC, Canada, 2023, pp. 5394-5403, doi: 10.1109/CVPR52729.2023.00522.

四、研究内容（本节可以整页扩页）

1. 研究构想与思路、主要研究内容及拟解决的关键问题（不少于 1000 字）

本课题针对基于深度学习的点云配准展开研究，针对现阶段技术的不足进行改进，之后再在此基础上提出更优秀的模型，分阶段进行实验，并对实验结果进行分析，并找到问题，通过查阅资料、阅读文献对算法进行进一步的改进，直到达到预期的指标。在算法测试初步确定可行后，在工业背景下进行实验，得到更加具有说服力的数据。

本课题的主要研究内容包括如下：

1) 点云特征提取

点云数据在存储中的排列往往是无序，从 PointNet 开始，一大批学者就更加注重解决在特征提取阶段如何提取到点云的几何特征、局部特征、优化全局特征等等，在实现点云的配准、点云分类、点云分割等等任务的过程中，都要从如何优化点云特征的提取性能入手，只有学习到了优秀的特征才能更好的完成接下来的任务。

而点云受采集设备以及坐标系影响，同一个物体使用不同的设备或者位置扫描，三维点的排列顺序千差万别，这样的数据很难直接通过 End2End 的模型处理。同时点云也具有稀疏性，在机器人和自动驾驶的场景中，激光雷达的采样点覆盖相对于场景的尺度来讲，具有很强的稀疏性。在 KITTI 数据集中，如果把原始的激光雷达点云投影到对应的彩色图像上，大概只有 3% 的像素才有对应的数据点。这种极强的稀疏性让基于点云的高层语义感知变得尤其困难。点云的数据结构就是一些三维空间的点坐标构成的点集，本质是对三维世界几何形状的低分辨率重采样，因此只能提供片面的几何信息，所以如何有效提取点云数据的特征一直是研究的重点。

本课题将重点之一放在点云的特征提取方面，拟采用多尺度特征提取、交叉特征融合等技术使模型尽可能学习到更多的特征，在提取点云局部几何特征的同时兼顾全局特征，提高性能的同时提高网络模型的鲁棒性。

2) 点云特征匹配

特征匹配是指找到两个点云中具有相似特征的点，并将它们对应起来。这是点云配准的关键步骤之一，因为只有找到了正确的特征匹配，才能将两个点云对齐，所以特征匹配的准确率往往决定了点云配准的准确率。

常规特征匹配通常是通过计算每个点的特征描述符来实现的。特征描述符是一个向量，它表示了一个点的局部特征。在点云配准中，常用的特征描述符包括 SHOT、FPFH、PFH 等。这些特征描述符可以通过计算点云中每个点周围的几何信息来得到。一旦得到了两个点云中每个点的特征描述符，就可以通过计算它们之间的距离来找到最佳匹配，常用的匹配算法有最近邻算法等。

近年来，深度学习技术的发展为点云配准带来了新的思路和方法，而本课题的第二个研究重点便落在该模块，本课题拟使用深度神经网络来学习点云的特征表示后进行特征匹配，只有精确的特征匹配，得到正确的对应点，才能在接下来的任务中获取最佳的变换矩阵。

3) 配准变换矩阵求解

在得到两组点云之间的对应关系之后，需要求解两组点云的变换矩阵进而完成配准，而常用的求解方法包括，随机采样一致性(RANSAC)算法、奇异值分解(SVD)算法等，RANSAC算法可以在存在噪声和异常点的情况下求解变换矩阵。其基本思想是随机选择一组点对，然后通过计算它们之间的变换矩阵，然后应用来评估配准的准确性。这个过程可以重复多次，最终选择具有最多匹配点对的变换矩阵作为最终结果。SVD 算法是一种常用的线性代数算法，它可以将一个矩阵分解为三个矩阵的乘积，从而得到矩阵的奇异值和奇异向量。在点云配准中，可以将两个点云的坐标矩阵拼接成一个大矩阵，然后对这个矩阵进行 SVD 分解，得到两个点云之间的最优变换矩阵，这个过程的核心其实是求解一个最优化问题，旨在最小化点云对应点之间的欧氏距离从而实现配准的任务。

1. 离群点剔除

本课题为保证获取到的点云数据是完整，精确的，需要融合使用离群点剔除技术，而离群点剔除不能单单出现在配准前后的去噪，如果在配准前去噪过度，会造成特征点的丢失，导致两组点云的对应点错匹配，从而导致准确率下降。而单单只在配准后进行离群点剔除，并不能提高配准技术的准确率，只是优化了点云模型的呈现效果，所以从根源上解决此问题，要在特征的提取与融合阶段进行改进，所以本课题在使用多尺度特征提取的基础上，拟采用交叉特征融合方法，允许源点云和目标点云的特征在融合阶段相互影响相互调整，从而减少离群点的错匹配，也就在配准结果产生时，减少离群点的出现概率，从而提高整体的准确率和鲁棒性。

本课题拟解决的关键问题如下：

1) 无法有效捕捉全局信息。

GeoTransformer 的提出，推动了 Transformer 模型在三维几何数据上的应用，它使用了一种几何转换模块来捕获点云内部的几何结构和点云间的几何一致性，这个模块由一个用于学习点云内部特征的几何自注意力模块和一个基于特征的交叉注意力模块组成，但是该模块是对每个独立的点进行几何变换，又由于模型处理的基本单元为超点（通常是由多个相邻的点聚合形成的），所以该模型在全局特征的捕获上有所欠缺，并且受超点规模影响，在面对不同分辨率的点云数据时处理结果会不稳定。

2) 对异常值和噪声点敏感问题。

GeoTransformer 网络如同其他点云配准网络一样，对于异常值和噪声点异常敏感，一旦

将噪声点与点云内点匹配，在配准后将可能会出现较多的离群点，影响准确率和鲁棒性，为了改进此缺陷，需要从多方面入手，不仅仅是对离群点剔除的后处理，也要针对特征融合、特征匹配模块进行改进，减小将噪声点错配的可能性，进而提高准确率和鲁棒性。

2. 拟采取的研究方法、技术路线、实施方案及可行性分析

本课题拟采用的研究方法主要以 GeoTransformer 作为基本结构实现性能更好、准确率更高、鲁棒性更好的点云配准网络模型为主，在此基础上，应用于工业项目背景，实现对点云的高质量自动配准。数据集拟采用网络公开数据集，再进一步研究中可能会对数据集进行筛选重建，以更适用于项目背景。对于基础网络搭建由开源的 GeoTransformer 模型为基础，在此基础上进行多尺度特征提取模块的添加，以此来提高模型的特征学习能力，但是该操作为了保留尽可能多的特征需要在特征融合阶段采取拼接等方法，但是会带来庞大的计算量，所以考虑在模型一基础上进一步改进，采用多尺度特征的鲁棒点匹配，来保证不丢失每一个尺度尺度特征的前提下减小计算量。进一步，将对该网络进行离群点剔除与减少离群点错匹配相结合的方式，搭建出增强网络，并实验测试，最后在证实模型具备可行性和优秀的性能后，应用于工业项目，用于生成工件的高精度点云模型。

本课题的技术路线分别如图 5，图 6 和图 7 所示：




图 5 基于 GeoTransformer 的多尺度特征融合点云配准网络

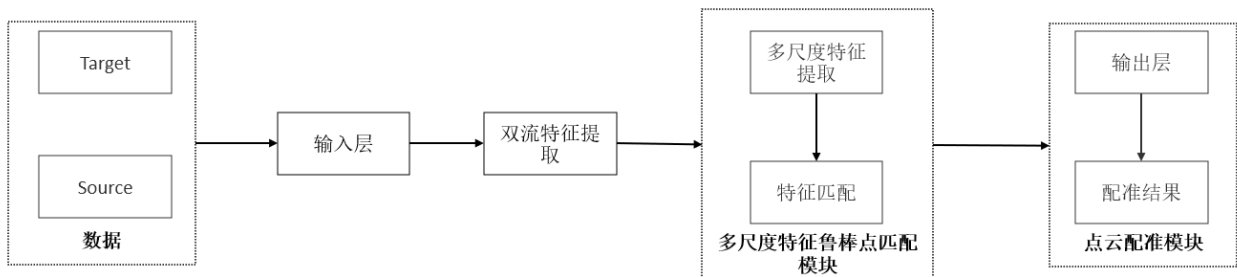


图 6 基于 GeoTransformer 多尺度特征鲁棒点匹配的点云配准网络

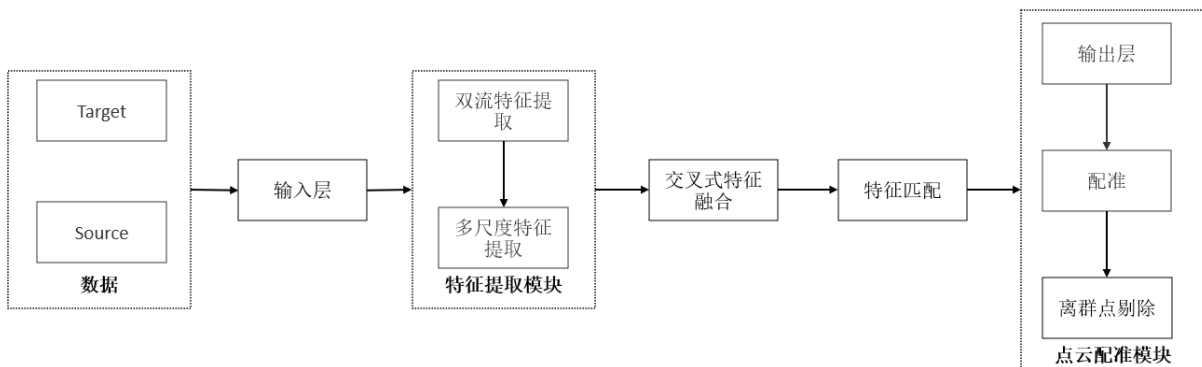


图 7 融合离群点剔除的基于 GeoTransformer 的多尺度特征融合增强网络

1) GeoTransformer

GeoTransformer 是近期基于 Transformer 提出的点云配准模型，其应用了一种几何转换方法使得模型更针对几何数据的优化处理，相比较使用 Transformer 结构，能更有效捕捉点云间的空间关系，更适用点云数据的处理，但是正由于这种几何转换方法是对每个点独立进行变换，这就导致它会忽略一定的全局信息。并且像大多数点云配准算法一样，GeoTransformer 对于噪声和异常值特别敏感，往往一个噪声点就能影响一片点云的配准效果，导致配准后出现过多离群点。

本课题也将以此模型为基本特征提取结构，以提高其准确率与鲁棒性，优化其不足为目标进行展开。

2) 输入层

此模块会将原始点云数据做预处理，包括采样，降噪等，并且得到网络所需要的数据形式，再分别传入特征提取模块。

3) 双流特征提取

为了提高处理速度算法性能，学习采用双流特征提取，分别对源点云数据和目标点云数据进行处理，使其在此阶段互不干扰，互不影响，而此模块应用的基本模型即为 GeoTransformer 网络模型，再将处理得到的基本特征分别传入下一个模块。

4) 多尺度特征提取

针对 GeoTransformer 模型会丢失全局信息的不足，采用多尺度特征提取的方法，来提升整个网络模型特征的学习效果，通过下采样的方式来实现类似“特征金字塔”的效果来对不同分辨率下的特征进行学习，从而提高算法的性能和鲁棒性。

5) 特征融合

根据提取到的多尺度的特征进行融合，包括拼接，池化，点乘等融合方法，本课题拟采用拼接的方法，尽可能保留较多的特征，提高系统的准确性和鲁棒性，而在改进中，采用交叉式融合方法，允许源点云和目标点云的特征相互影响和调整，以此来增强特征融合模块所完成的工作，进一步提高系统的鲁棒性。

6) 特征匹配

特征匹配是指在得到两组点云的特征后，依据学习到的特征进行对应点之间的匹配，主要步骤包括描述子生成和匹配算法。在特征提取阶段，网络已经识别点云中的关键点（如边缘、角点或具有独特几何结构的点）来获取到了感兴趣的区域。随后，在描述子生成阶段，为这些关键点生成局部描述子，这些描述子是通过编码关键点周围的局部几何结构来生成的，能够捕获其唯一的空间特征。然后网络通过比较不同点云中的描述子来找出相似的对应点。通常涉及到计算描述子之间的距离（例如欧氏距离或余弦相似度），并根据设定的阈值或最近

邻准则来确定匹配对。在本课题中拟采用神经网络进行匹配处理优化，以实现更高效和准确的特征匹配。

7) 输出层与配准模块

该层的作用是基于对应点，来计算或拟合出最佳的变换矩阵，奇异值分解（SVD）被广泛认为是一种稳定且高效的方法，尤其适用于处理具有大量数据的复杂点云，所以本课题拟采用奇异值分解（SVD）来进行计算。之后基于变换矩阵对点云进行变换，并计算出准确率等数据用于参考调试。而对于模型二（基于 GeoTransformer 多尺度特征鲁棒点匹配的点云配准网络）来说，输出层需要做的工作不仅仅是这个，而是需要将每个尺度的匹配结果输出后进行滤波处理再合并，形成最终的配准结果。

8) 离群点剔除模块

为了提高配准后点云的完整性和准确性，本课题添加后处理模块的离群点剔除模块，此过程通常是基于点对之间的距离来计算置信度，然后根据这些置信度剔除那些可能错误匹配的点对。具体来说，一旦点云配准网络找到了匹配的点对，后处理模块会计算每对匹配点之间的欧氏距离。这些距离用于评估匹配的质量，距离越小，置信度越高。接着设置一个阈值，只保留距离小于该阈值的匹配点对，这样就可以剔除那些距离较大的匹配点对。这个阈值可以是固定的，也可以是根据所有匹配点对距离的统计数据（如平均值或标准差）动态计算的。通过这种方法可以提高配准结果的整体精度和可靠性，在应用于工业背景时，也有利于高精度点云数据的呈现。

可行性分析：

1) 技术可行性

对于基于 GeoTransformer 的多尺度特征融合点云配准网络及其改进模型，其技术可行性涉及评估 GeoTransformer 架构在处理大规模点云数据时的有效性，而 GeoTransformer 的提出就已证明其处理点云的有效性和可行性，以及证明它在不同层次上捕捉几何特征的能力。此外，结合 GeoTransformer 架构的优势和多尺度特征融合的方法，理论上提供了对复杂空间关系的高效处理能力。这种结合在理论上是创新的，对提高点云配准的精度和效率具有积极作用。个人在学习工作过程中对于点云处理已经有了一定的基础，而此前对于深度学习方面的知识也有所应用研究。所以这一项目在理论上是可行的，但需要此后进一步的实验和开发来验证其实际效果和效率。

2) 应用需求

基于工业项目背景，需要获取高精度的点云模型进行进一步操作，而本课题所研究方法

即可应用于此，辅助其提高整体的性能与表现。而且此项目对于其他领域，如三维重建、自动驾驶、测绘等都可提供有效帮助和借鉴意义。

3) 风险评估

该项目进程中可能遇到的资源硬件上的风险如算力支持等，可以使用服务器或者云算力进行支持。另外考虑到在开发过程中可能遇到的问题，例如算法稳定性较差，精确度未达到预期等，会及时查阅相关资料，做出相应调整。整体项目的工作量在有效时间内也是可按计划完成的。通过对风险因素的分析 and 评估，可以制定相应的风险缓解策略和应对措施，从而降低项目失败的风险，确保本课题顺利进行

五、预期研究成果（本节可以整页扩页）

对所研究的成果进行阐述，同时要要与前文研究内容的相关性及与前人（他人）研究成果的差异性进行描述

本课题的预期成果：

1) 功能上：根据整体设计路线，实现点云的多尺度特征提取、点云的特征融合、特征匹配等技术，以此实现一套抗噪声能力强、对工业生产环境更加鲁棒的点云配准方法。

2) 性能上：在上述列举的数据集上与 SOTA 方法相比，性能优于 SOTA 方法。运用到实际工业场景中，能准确地实现不同视角下点云数据的配准，或者高精度的完整点云模型。

3) 可量化成果：根据研究课题发表论文一篇。

与前文研究内容的相关性：

1) 现有研究通过对点云数据的离群点剔除技术来获得更完整精确的点云模型，此技术不光在点云领域，在图像领域也有着一定应用和研究。

2) 现有研究使用 GeoTransformer 模型完成了点云配准的任务。

3) 现有研究使用特征金字塔技术或多尺度特征技术，来提高模型的特征学习能力，来增强模型的性能。

与前人研究成果的差异性：

现有的方法同样可以分为基于传统方法的配准方法和基于深度学习的配准方法，对于基于传统方法的配准方法来说，本课题的研究方法与此类方法的核心思路、所用技术等等均有较大差异。

对现有的基于深度学习的方法来说，本课题采用的基本模型为 GeoTransformer，并非主流的 PointNet 或者 PointNet++。然而，整个点云的全局特征在此模型上未完全考虑，这必然会影响到最终配准点云的精度。与之前的研究相比，本课题提出的方法引入了多尺度特征提取的方案。通过将不同分辨率下的特征进行融合，使得模型能学习到更多的特征，能够更好地进行点云配准任务。

本课题的方法也考虑到该模型对于噪声点和异常值的敏感问题。在此基础上，采用交叉特征融合方式结合后处理模块的离群点剔除算法，增强网络对噪声点的抗性，提高整体配准的准确率和鲁棒性。

六、研究条件（本节不允许扩页）

1. 所需实验手段、研究条件和实验条件

（如果没有，可以空白）

所需实验手段：

- 1) 点云处理相关基础知识学习和算法的理论学习研究；
- 2) 离群点剔除相关算法的学习研究；
- 3) GeoTransformer 网络框架搭建的学习研究。

研究条件和实验条件

- 1) 工作站一台；
- 2) PC 机一台；
- 3) 可获取的云算力支持。

2. 所需经费，包含经费来源、开支预算（工程设备、材料须填写名称、规格、数量）

（如果没有，可以空白）

七、工作计划（本节不允许扩页）

序号	阶段及内容	工作量估计 (时数)		起止日期	阶段研究成果
1	论文研读及方向确定	750		2023.08.01- 2023.10.31	文献综述
2	确定选题和大致的研究方法	250		2023.11.01- 2024.11.30	开题报告
3	算法一搭建与实验	500		2024.12.01- 2024.01.31	算法模型一的相关 实验数据
4	算法二搭建与实验，并对算法一 持续优化	750		2024.02.01- 2024.05.31	算法模型二的相关 实验数据
5	对各部分研究成果整合并在工程 中实验测试及应用	500		2024.06.01- 2024.08.31	两个模型在工程中的 应用实验数据
6	于 SOTA 方法进行实验对比，进 行消融实验	250		2024.09.01- 2024.09.30	消融实验报告
7	获得整体数据，撰写论文及相关 专利	500		2024.10.01- 2024.11.30	相关专利申请，论 文初稿
8	毕业论文的持续完善	1000		2024.12.01- 2025.03.31	毕业论文
9					
		合计	4500		